O DATASET DE GINÁSIO É SINTÉTICO

Como o provei em cinco testes, e o que isso faz às análises do costume.

$R^2 = 1{,}00$
bom demais para ser real

Leodgar
Projeto de portefólio, 2026

O PONTO DE PARTIDA

01

Dataset do Kaggle
973 membros de ginásio, 15 colunas, sem valores em falta.

02

A análise do costume
Calorias, duração das sessões e segmentos de membros.

03

Resultados bons demais
Uma regressão simples explicava 100% das calorias.

04

Mudei de pergunta
Fui ver como os dados tinham sido feitos.

R^2

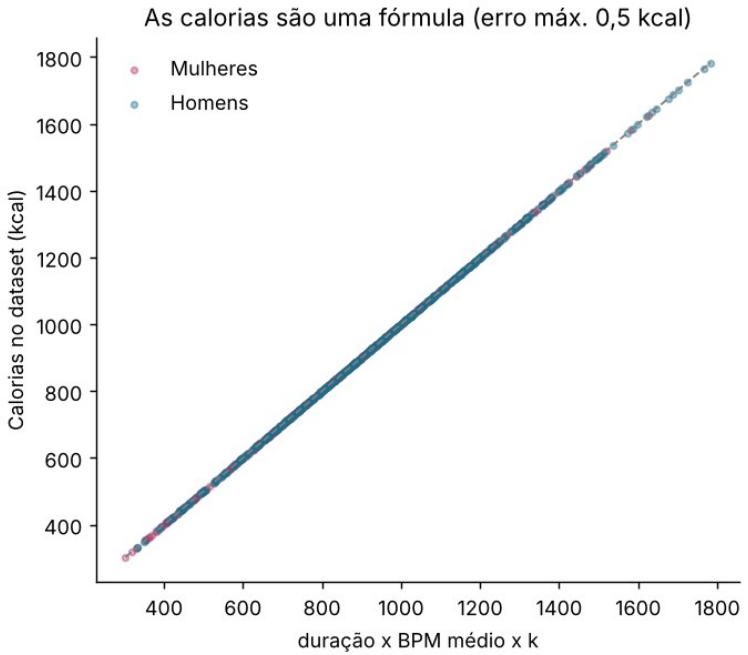
1,00

Não aparece em dados de pessoas.

PROVA 1: UMA FÓRMULA

calorias = duração × BPM médio × k

- O k vale 5,0 nas mulheres e 5,5 nos homens.
- O erro máximo nas 973 linhas é 0,5 kcal, que é o arredondamento.
- Peso, altura e tipo de treino não entram na conta.

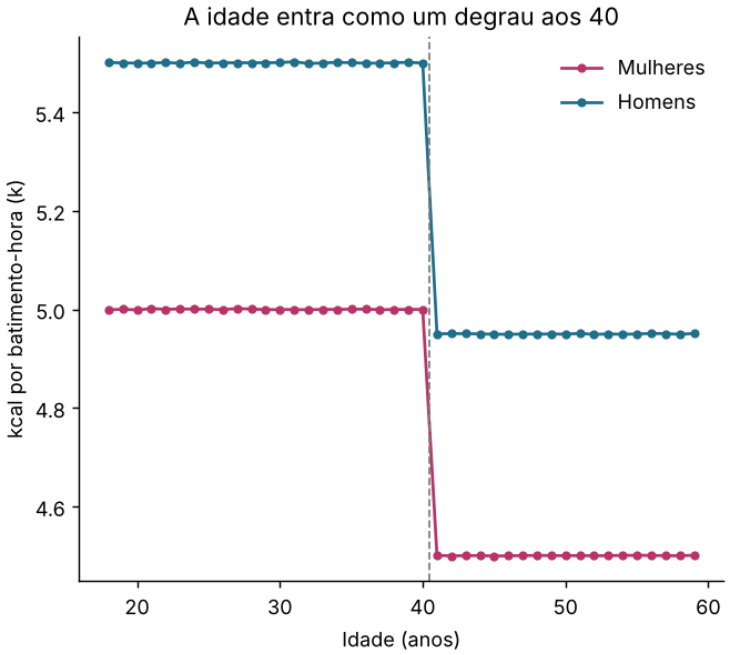


PROVA 2: O DEGRAU DOS 40

−10%

aos 41 anos, de um ano para o outro

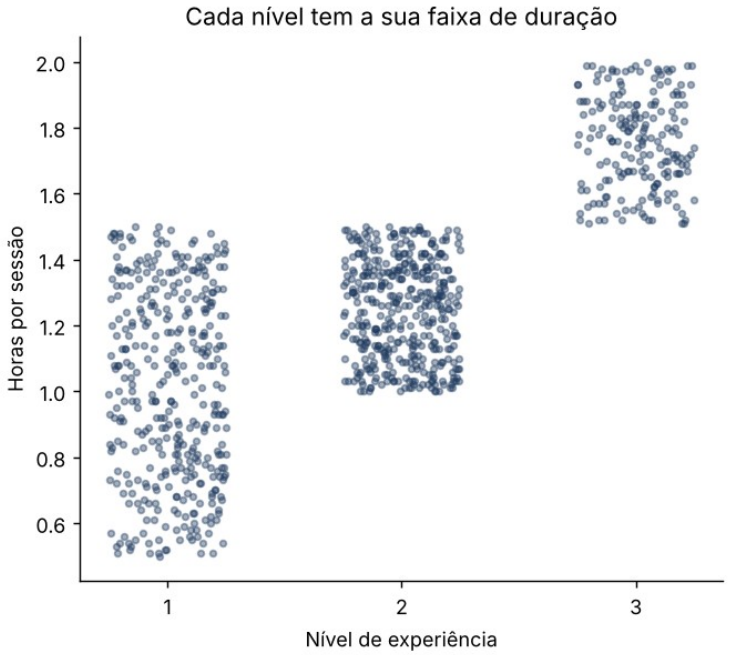
A correlação entre idade e calorias (r = −0,16) faz pensar numa descida gradual. Antes e depois dos 40, a idade deixa de contar.



PROVA 3: FAIXAS FIXAS

Nível	Horas por sessão	Dias por semana	% de gordura
1	0,5 a 1,5	2 a 3	20 a 35
2	1,0 a 1,5	3 a 4	20 a 35
3	1,5 a 2,0	4 a 5	10 a 20

Não há uma única exceção. Dentro de cada faixa a duração é uniforme (Kolmogorov-Smirnov, p entre 0,42 e 0,70).



PROVA 4: RELAÇÕES EM FALTA

−0,02

Idade e BPM máximo
Devia descer com a idade.

−0,12

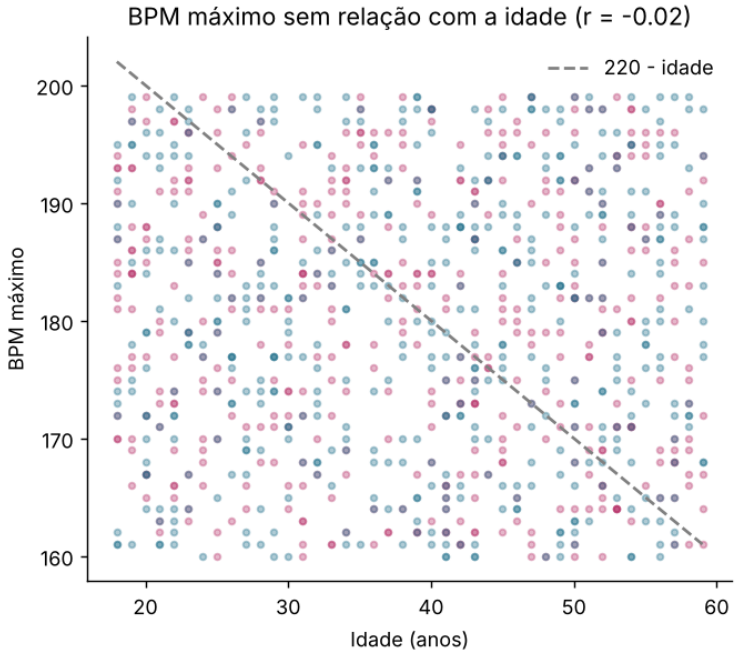
IMC e % de gordura
Deviam subir juntos.

0,00

Idade e % de gordura
Devia subir com a idade.

0,00

Nível e BPM em repouso
Mais treino devia baixá-lo.

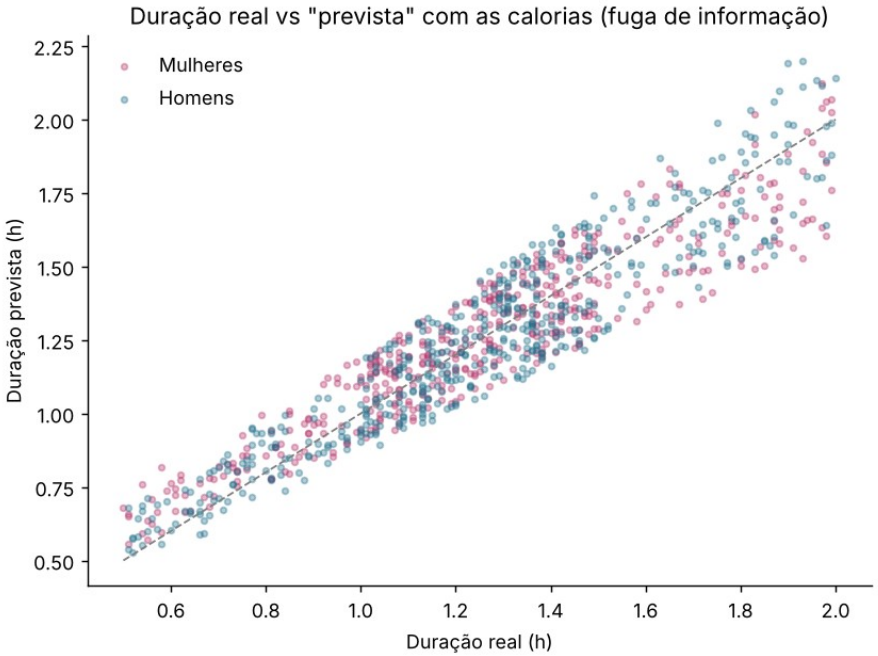


QUANTO DÁ PARA PREVER

0,62
R^2 só com o nível

0,87
R^2 com as calorias

O segundo número é fuga de informação: as calorias só existem depois da sessão e foram calculadas a partir da duração. Antes da sessão, o teto é 0,62.

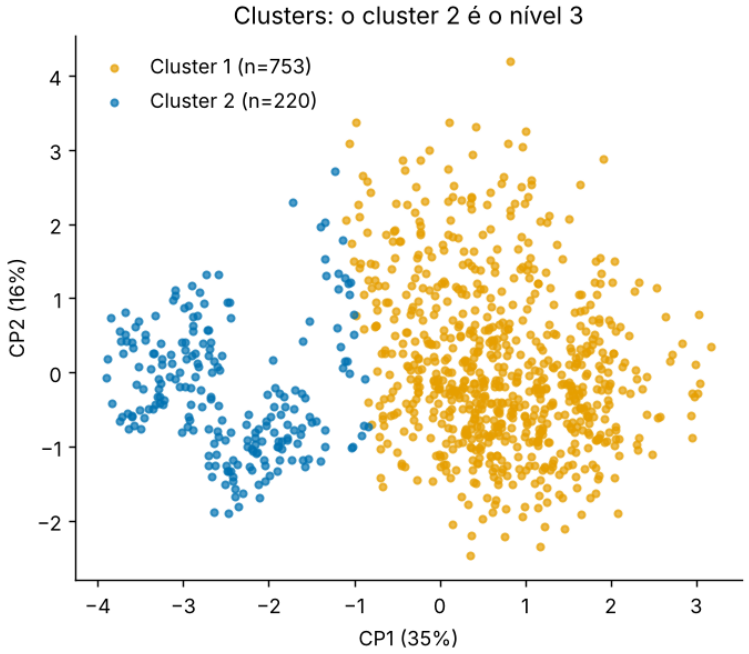


CLUSTERS: NADA DE NOVO

0,27
silhueta: estrutura fraca

0,87
ARI contra “nível 3 ou não”

Os segmentos que o algoritmo encontrou são uma coluna que já estava no ficheiro. Deixei-o no projeto como resultado negativo.



O QUE LEVO DAQUI

1. Testar se o alvo é uma conta das outras colunas.
2. Ver as médias por valor antes de ajustar uma reta.
3. Calcular as correlações dentro de cada grupo.
4. Cruzar os clusters com as colunas que ficaram de fora.
5. Perguntar se o preditor existe quando a previsão é feita.

Com dados reais

Começava por um modelo de abandono e pela ocupação por hora. Este ficheiro não tem datas nem histórico, por isso não permite nenhuma das duas.

REPOSITÓRIO

github.com/pintoleodgar/gym_projet
Código, figuras e dicionário de dados.

Leodgar
Python, pandas, scikit-learn, statsmodels